

عنوان پروژه:

پیش‌بینی بیماری قلبی با استفاده از الگوریتم Logistic Regression و مقایسه روش‌های Encoding

مخزن پروژه:

https://github.com/Nargesazizollahi/heart-disease-logistic-regression?utm_source=chatgpt.com

چکیده

در این پروژه، یک مدل یادگیری ماشین برای تشخیص بیماری قلبی با استفاده از الگوریتم Logistic Regression پیاده‌سازی شده است. هدف اصلی، بررسی تأثیر دو روش مختلف تبدیل ویژگی categorical و One-Hot Encoding شامل Label Encoding است. همکرد مدل می‌باشد. متغیر هدف دیتاست که در ابتدا دارای پنج سطح شدت بیماری بود، به یک مسئله طبقه‌بندی دودویی تبدیل شد (وجود یا عدم وجود بیماری). برای ارزیابی عملکرد مدل از روش 10-Fold Cross Validation استفاده شد و معیارهای Accuracy، Precision و Recall از الگوریتم Logistic Regression گزارش گردیدند. نتایج نشان داد که روش One-Hot Encoding به دلیل جلوگیری از القای ترتیب مصنوعی بین دسته‌ها، عملکرد بهتری به ویژه در معیار Recall و F1-score ارائه می‌دهد. با توجه به اهمیت کاهش خطای منفی کاذب در کاربردهای پزشکی، One-Hot Encoding گزینه مناسب‌تری برای این مسئله تشخیص داده شد.

۱. مقدمه

هدف این پروژه، پیاده‌سازی یک مدل یادگیری ماشین برای تشخیص بیماری قلبی با استفاده از الگوریتم Logistic Regression است. علاوه بر آموزش مدل، تأثیر دو روش مختلف تبدیل متغیر categorical و One-Hot Encoding شامل Label Encoding بر عملکرد مدل مورد بررسی قرار می‌گیرد. مسئله به صورت طبقه‌بندی دودویی تعریف شده است (وجود یا عدم وجود بیماری). برای ارزیابی عملکرد مدل از روش 10-Fold Cross Validation و معیارهای Precision، Accuracy، Recall و F1-score استفاده شده است.

۲. آماده سازی داده‌ها**۲-۱ معرفی دیتاست**

در این پروژه از دیتاست Heart Disease استفاده شده است که شامل ویژگی‌های بالینی بیماران بوده و متغیر هدف آن با نام num مشخص می‌شود.

در دیتاست اصلی، متغیر num دارای پنج مقدار مختلف است:

- ۰ : عدم وجود بیماری
- ۱ تا ۴ : وجود بیماری با شدت‌های مختلف

از آنجا که هدف پروژه طبقه‌بندی دودویی است، این متغیر به دو کلاس تبدیل شد که در بخش پیاده‌سازی کد توضیح داده می‌شود.

$$\begin{aligned} num &= 0 \rightarrow -1 \\ num &= 1,2,3,4 \rightarrow +1 \end{aligned}$$

۲-۲ بررسی توزیع کلاس‌ها

پس از تبدیل متغیر هدف به حالت دودویی، توزیع کلاس‌ها بررسی شد.

```
print("Class distribution after binarization:")
print(df['num'].value_counts())
```

```
Class distribution after binarization:
```

```
num
 1  509
-1  411
```

شکل ۱ - توزیع کلاس‌ها پس از دودویی‌سازی متغیر هدف

همان‌طور که در شکل ۱ مشاهده می‌شود، تعداد نمونه‌های کلاس مثبت ۵۰۹ و کلاس منفی ۴۱۱ است. اگرچه اختلاف جزئی وجود دارد، اما داده‌ها نسبتاً متوازن هستند. با این حال در تحلیل عملکرد مدل توجه ویژه‌ای به معیار Recall شده است.

۳-۲ تبدیل متغیر هدف به طبقه‌بندی دودویی

در دیتابیست اصلی، متغیر هدف num دارای پنج سطح مختلف (۰ تا ۴) است. از آنجا که هدف پژوهه طراحی یک مدل طبقه‌بندی دودویی است، این متغیر به دو کلاس تبدیل شد:

- مقدار ۰ : کلاس ۱ - عدم وجود بیماری
- مقدار ۱ تا ۴ : کلاس ۱ + وجود بیماری

```
df['num'] = df['num'].apply(lambda x: -1 if x == 0 else 1)
```

تابع df['num'] ستون هدف را انتخاب می‌کند.

تابع apply() برای اعمال یک تابع روی تمام مقادیر ستون استفاده می‌شود.

عبارت lambda x: -1 if x == 0 else 1 یک تابع ناشناس است که:

- اگر مقدار برابر ۰ باشد، مقدار ۱ بر می‌گرداند.
- در غیر این صورت مقدار ۱+ اختصاص می‌دهد.

این مرحله باعث تبدیل مسئله از حالت چندکلاسه به طبقه‌بندی دودویی شد.

۳. پیاده‌سازی مدل

۱-۳ وارد کردن کتابخانه

```
import pandas as pd
import numpy as np

from pathlib import Path
from sklearn.impute import SimpleImputer
from sklearn.model_selection import KFold, cross_validate
from sklearn.preprocessing import OneHotEncoder, LabelEncoder, StandardScaler
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LogisticRegression
```

- pandas : برای مدیریت دادهها.
- numpy : برای محاسبات عددی مثل میانگین و انحراف معیار.
- KFold : برای اعتبارسنجی متقطع ۱۰ بخشی.
- cross_validate : برای محاسبه همزمان چند معیار روی K-Fold.
- Pipeline : برای اتصال مراحل پیش‌پردازش و مدل‌سازی.
- ColumnTransformer : برای اعمال پیش‌پردازش مختلف روی ستون‌های عددی و categorical.
- LabelEncoder و OneHotEncoder : برای دو روش encoding ستون.
- StandardScaler : برای استانداردسازی ویژگی‌های عددی.
- SimpleImputer : برای جایگزینی مقادیر گمشده داخل Pipeline.
- LogisticRegression : مدل اصلی طبقه‌بندی.

۲-۳ بارگذاری داده

در این مرحله فایل دیتاست از پوشه data/ خوانده می‌شود:

```
df = pd.read_csv("data/heart_disease_uci.csv")
```

این دستور فایل CSV را خوانده و آن را در قالب یک DataFrame در متغیر df ذخیره می‌کند. دیتافریم ساختاری جدولی دارد که امکان انجام پردازش‌های بعدی روی داده را فراهم می‌کند.

۳-۳ حذف برخی ویژگی‌ها

در این مرحله برخی از ویژگی‌های غیرپیوسته یا کم‌اهمیت حذف شدند تا تمرکز پژوهه بر مقایسه روش‌های Encoding برای ویژگی cp باشد.

```
drop_cols = ['sex', 'dataset', 'fbs', 'restecg', 'exang', 'slope', 'thal']
df = df.drop(columns=drop_cols)
```

در خط اول، یک لیست به نام drop_cols تعریف شده که شامل نام ستون‌هایی است که باید حذف شوند. در خط دوم، با استفاده ازتابع () drop این ستون‌ها از دیتافریم حذف می‌شوند. پارامتر columns= مشخص می‌کند که حذف بر اساس نام ستون انجام شود. نتیجه دوباره در df ذخیره شده است.

هدف از این کار ساده‌سازی مدل و باقی ماندن تنها یک ویژگی (cp) برای مقایسه دو روش Encoding بوده است.

۴-۳ جداسازی ویژگی‌ها و متغیر هدف

```
X = df.drop(columns=['num'])
y = df['num']
```

در خط اول، ستون هدف (num) حذف شده و باقی ستون‌ها به عنوان ویژگی‌ها در متغیر X ذخیره می‌شوند. در خط دوم، ستون num به عنوان متغیر هدف در y ذخیره می‌شود. این جداسازی در مسائل یادگیری نظراتی ضروری است.

۵-۳ تعیین ویژگی categorical و عددی

```
categorical_feature = ['cp']
numerical_features = [col for col in X.columns if col not in categorical_feature]
```

در خط اول مشخص شده که تنها ویژگی categorical برابر با cp است.
 در خط دوم با استفاده از List Comprehension تمامی ستون‌هایی که در لیست categorical نیستند، به عنوان ویژگی عددی در نظر گرفته می‌شوند.
 این تقسیم‌بندی برای اعمال پیش‌پردازش متفاوت ضروری است.

۴. طراحی Pipeline برای One-Hot Encoding

۱-۴ پیش‌پردازش ویژگی‌های عددی

```
num_pipeline = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', StandardScaler())
])
```

Pipeline برای اتصال چند مرحله پردازش به صورت زنجیره‌ای استفاده می‌شود.
 مرحله اول:

- SimpleImputer(strategy='median')
- مقادیر گمشده عددی را با میانه جایگزین می‌کند.
- استفاده از median به دلیل مقاومت در برابر داده‌های پرت است.

مرحله دوم:

- StandardScaler()
- داده‌ها را استاندارد می‌کند (میانگین صفر و واریانس یک).
- این کار برای مدل‌های خطی مانند Logistic Regression اهمیت دارد.

۲-۴ ترکیب پیش‌پردازش عددی و categorical

```
preprocess_onehot = ColumnTransformer([
    ('num', num_pipeline, numerical_features),
    ('cat', OneHotEncoder(drop='first'), categorical_feature)
])
```

اجازه می‌دهد روی ستون‌های مختلف پردازش متفاوت اعمال شود. ColumnTransformer

بخش اول:

- 'num' نام دلخواه این مرحله است.
- 'num_pipeline' روی ویژگی‌های عددی اعمال می‌شود.

بخش دوم:

- 'cat' نام دلخواه مرحله encoding است.
- 'OneHotEncoder(drop='first')' روی ستون cp اعمال می‌شود.
- 'Dummy Variable Trap' استفاده شده است (جلوگیری از همخطی کامل بین گزینه drop='first' برای جلوگیری از ویژگی‌ها).

۳-۴ ساخت مدل نهایی One-Hot

```
model_onehot = Pipeline([
    ('preprocess', preprocess_onehot),
    ('classifier', LogisticRegression(max_iter=1000))
])
```

در این Pipeline دو مرحله وجود دارد:

۱. preprocess شامل تمام مراحل آماده‌سازی داده

۲. Logistic Regression مدل classifier

پارامتر max_iter=1000 برای اطمینان از همگرایی کامل الگوریتم تنظیم شده است.

استفاده از Pipeline تضمین می‌کند که در هر Fold از Cross Validation:

- مراحل Encoding، Imputation و Scaling فقط روی داده‌های آموزش (Train) fit شوند.
- سپس همان تبدیل‌ها روی داده‌های آزمون (Test) اعمال شوند.

این موضوع از بروز Data Leakage جلوگیری می‌کند و ارزیابی علمی و صحیحی فراهم می‌سازد.

۵. طراحی Pipeline برای Label Encoding

در این بخش، ستون categorical یعنی cp به جای One-Hot Encoding به روشن Label Encoding می‌شود تا اثر نوع Encoding بر عملکرد مدل مقایسه گردد.

۶-۱ اعمال cp روی ویژگی Label Encoding

```
X_label = X.copy()
le = LabelEncoder()
X_label['cp'] = le.fit_transform(X_label['cp'])
```

یک کپی مستقل از داده‌ها می‌سازد تا تغییرات روی `X_label` باعث تغییر در `X.copy()` نشود. یک شیء برای تبدیل مقادیر `categorical` به عدد ایجاد می‌کند.

دو کار انجام می‌دهد:

۱. مقادیر منحصر به فرد `cp` را یاد می‌گیرد.

۲. هر مقدار را به یک عدد صحیح نگاشت می‌کند.

در نهایت، ستون `cp` در `X_label` عددی می‌شود.

در Label Encoding ممکن است مدل به اشتباه ترتیب عددی بین دسته‌ها را واقعی فرض کند) مثلاً `cp=3` بزرگ‌تر از `cp=1` ، در حالی که یک ویژگی Nominal است و ترتیب واقعی ندارد. به همین دلیل ممکن است عملکرد کاهش یابد.

۲-۵ پیش‌پردازش داده‌ها در حالت Label Encoding

```
preprocess_label = ColumnTransformer([
    ('num', num_pipeline, X_label.columns)
])
```

از آنجا که `cp` در این حالت به عدد تبدیل شده، دیگر `categorical` محسوب نمی‌شود . بنابراین تمام ستون‌ها (شامل `cp` و سایر ویژگی‌ها) وارد `num_pipeline` می‌شوند. شامل:

- جایگزینی مقادیر گمشده با `median`
- استانداردسازی با `StandardScaler`

این کار باعث می‌شود تنها تفاوت دو مدل در نوع Encoding باشد و بقیه مراحل کاملاً یکسان باقی بمانند.

۳-۵ ساخت مدل نهایی Label Encoding

```
model_label = Pipeline([
    ('preprocess', preprocess_label),
    ('classifier', LogisticRegression(max_iter=1000))
])
```

ساختار Pipeline مشابه مدل One-Hot است تا مقایسه منصفانه انجام شود.

تفاوت اصلی فقط در نحوه نمایش ستون `cp` است.

`max_iter=1000` برای جلوگیری از عدم همگرایی الگوریتم تنظیم شده است.

۶. تعریف معیارهای ارزیابی و Cross Validation

۱-۶ تعریف معیارها (Scoring)

```
scoring = {
    'accuracy': 'accuracy',
    'precision': 'precision',
    'recall': 'recall',
    'f1': 'f1'
}
```

یک دیکشنری به نام scoring تعریف شده است تا چند معیار به صورت همزمان محاسبه شوند.
معیارها:

• Accuracy: درصد پیش‌بینی درست کلی

• Precision: از بین پیش‌بینی‌های مثبت، چند درصد واقعاً مثبت بوده‌اند

• Recall: از بین مثبت‌های واقعی، چند درصد درست شناسایی شده‌اند (مهمترین معیار در پزشکی)

• F1-score: Precision و Recall میانگین هماهنگ

در مسائل پزشکی Recall بسیار مهم است، چون خطای False Negative (بیمار واقعی که سالم تشخیص داده شود) خطرناک‌تر است.

۲-۶ تعریف 10-Fold Cross Validation

```
kf = KFold(n_splits=10, shuffle=True, random_state=42)
```

n_splits=10 یعنی داده به ۱۰ بخش تقسیم می‌شود.
shuffle=True باعث می‌شود قبل از تقسیم‌بندی، داده‌ها تصادفی مخلوط شوند.
random_state=42 باعث می‌شود نتایج قابل تکرار (Reproducible) باشند.
استفاده از تنظیمات ثابت برای هر دو مدل باعث می‌شود مقایسه دو روش Encoding کاملاً منصفانه باشد.

۷-۱ اجرای ارزیابی مدل‌ها

۷-۲ اجرای Cross Validation برای مدل One-Hot

```
scores_onehot = cross_validate(model_onehot, X, y, cv=kf, scoring=scoring)
print("One-Hot Encoding Results:", scores_onehot)
```

۱۰-Fold Cross Validation مدل را با استفاده از cross_validate() ارزیابی می‌کند.

پارامترها:

- Logistic Regression+ model_onehot مدل شامل پیش‌پردازش
- X ویژگی‌ها
- y متغیر هدف
- cv=kf شیء تعریف‌شده KFold
- scoring=scoring معیارهای ارزیابی

خروجی این تابع یک دیکشنری شامل آرایه‌ای از نتایج هر معیار برای هر Fold است. دستور print برای مشاهده جزئیات کامل نتایج هر Fold استفاده شده است.

۷-۲ اجرای Cross Validation برای مدل Label Encoding

```
scores_label = cross_validate(model_label, X_label, y, cv=kf, scoring=scoring)
print("Label Encoding Results:", scores_label)
```

۸. خلاصه‌سازی نتایج (Mean ± Std)

۱-۸ تعریف تابع خلاصه سازی

```
def print_summary(scores, title):
    print(f"\n{title} - Mean ± Std")
    for metric in ['test_accuracy', 'test_precision', 'test_recall', 'test_f1']:
        mean = np.mean(scores[metric])
        std = np.std(scores[metric])
        name = metric.replace('test_', '').capitalize()
        print(f"{name}: {mean:.3f} ± {std:.3f}")
```

یک تابع به نام print_summary تعریف شده که:

- ورودی اول scores: (خروجی cross_validate)
- ورودی دوم: title (عنوان مدل)

در حلقه for، هر معیار ارزیابی بررسی می‌شود.

`np.mean()` میانگین عملکرد در Fold ۱۰ را محاسبه می‌کند.

`np.std()` میزان نوسان عملکرد (پایداری مدل) را محاسبه می‌کند.

`replace('test_', '')` برای خواناتر شدن نام معیار استفاده شده است.

خروجی به صورت $\text{Mean} \pm \text{Std}$ چاپ می‌شود.

گزارش $\text{Mean} \pm \text{Std}$ نشان می‌دهد مدل نه تنها چه عملکردی دارد، بلکه چقدر پایدار است و به یک تقسیم‌بندی خاص وابسته نیست.

```
print("\n===== SUMMARY =====")
print_summary(scores_onehot, "One-Hot Encoding")
print_summary(scores_label, "Label Encoding")
print("=====\\n")
```

ابتدا یک خط جداگانه چاپ می‌شود. سپس نتایج مدل One-Hot Encoding خلاصه می‌شود. بعد نتایج مدل Label Encoding چاپ می‌شود. در نهایت خروجی مرتب و قابل ارائه تولید می‌شود.

۹. تحلیل نتایج

نتایج به دست آمده نشان داد که روش One-Hot Encoding عملکرد بهتری نسبت به Label Encoding دارد.

این موضوع از نظر تئوری نیز قابل توجیه است، زیرا:

- ویژگی Nominal دارد و ترتیب واقعی بین دسته‌ها وجود ندارد.

- ممکن است به مدل القا کند که بین مقادیر رابطه ترتیبی وجود دارد.

- این مشکل را برطرف می‌کند و هر دسته را به صورت مستقل نمایش می‌دهد.

از منظر کاربرد پژوهشی، معیار Recall اهمیت بیشتری دارد، زیرا کاهش خطای منفی کاذب (بیمار واقعی که سالم تشخیص داده شود) حیاتی است. بنابراین با توجه به Recall بالاتر، روش One-Hot Encoding انتخاب مناسب‌تری برای این مسئله محسوب می‌شود.

۱-۹ نتایج عددی

در این بخش، عملکرد دو روش Encoding با استفاده از Fold-10 Cross Validation مقایسه شده است.

جدول ۱- مقایسه عملکرد دو روش کدگذاری (Mean \pm Std)

Results (10-Fold Cross Validation)

The model was evaluated using 10-fold cross validation. Missing values were handled using `SimpleImputer` inside the pipeline to avoid data leakage.

Encoding Method	Accuracy (Mean \pm Std)	Precision (Mean \pm Std)	Recall (Mean \pm Std)	F1-score (Mean \pm Std)
One-Hot Encoding	0.809 \pm 0.048	0.822 \pm 0.053	0.833 \pm 0.081	0.825 \pm 0.055
Label Encoding	0.803 \pm 0.047	0.822 \pm 0.048	0.818 \pm 0.090	0.818 \pm 0.059

Conclusion: One-Hot Encoding achieved slightly better overall performance, especially in Recall and F1-score.

همان‌طور که در جدول ۱ مشاهده می‌شود، روش One-Hot Encoding عملکرد بهتری ارائه داده است.

۲-۹ نمایش گرافیکی نتایج


```

15 ===== SUMMARY =====
16 One-Hot Encoding - Mean ♦ Std
17 Accuracy : 0.809 ♦ 0.048
18 Precision : 0.822 ♦ 0.053
19 Recall : 0.833 ♦ 0.081
20 F1 : 0.825 ♦ 0.055
21
22 Label Encoding - Mean ♦ Std
23 Accuracy : 0.803 ♦ 0.047
24 Precision : 0.822 ♦ 0.048
25 Recall : 0.818 ♦ 0.090
26 F1 : 0.818 ♦ 0.059
27
28 =====
29
30

```


شکل ۲- نتایج اعتبارسنجی متقطع ۱۰ بخشی برای دو روش Encoding

به منظور در ک بهتر تفاوت عملکرد دو روش Encoding ، مقایسه گرافیکی معیارهای Recall و F1-score ارائه شده است.



شکل ۳ - مقایسه Recall برای دو روش Encoding

همان طور که در شکل ۳ مشاهده می شود، مقدار Recall One-Hot Encoding در روش Label Encoding بالاتر از است. این موضوع نشان می دهد که مدل در حالت One-Hot توانایی بیشتری در شناسایی بیماران واقعی (کلاس مثبت +) دارد و احتمال خطای منفی کاذب کاهش یافته است. با توجه به اهمیت تشخیص صحیح بیماران در کاربردهای پزشکی، این اختلاف هرچند اندک، از نظر عملی حائز اهمیت است.



شکل ۴ – مقایسه F1-score برای دو روش Encoding

طبق شکل ۴، مقدار F1-score در روش Label Encoding نیز اندکی بالاتر از One-Hot Encoding است. این نتیجه نشان می‌دهد که علاوه بر افزایش Recall، تعادل کلی میان Precision و Recall نیز در روش One-Hot بهتر حفظ شده است. بنابراین، از منظر عملکرد کلی مدل، One-Hot Encoding انتخاب مناسب‌تری برای این مسئله محسوب می‌شود.

۱۰. نتیجه گیری

در این پژوهه، الگوریتم Logistic Regression برای تشخیص بیماری قلبی پیاده‌سازی شد و تأثیر دو روش Encoding مختلف مورد مقایسه قرار گرفت. ارزیابی با استفاده از 10-Fold Cross Validation انجام شد و معیارهای Precision، Accuracy و Recall F1-score گزارش گردید.

نتایج نشان داد که One-Hot Encoding عملکرد بهتری ارائه می‌دهد، بهویژه در معیار Recall که در کاربردهای پزشکی اهمیت بالایی دارد. بنابراین برای ویژگی‌های Nominal و categorical از نوع One-Hot Encoding استفاده از این روش توصیه می‌شود.

۱۱. ساختار پژوهه و سازمان‌دهی فایل‌ها

در این پژوهه، ساختار پوشه‌ها و فایل‌ها مطابق نسخه موجود در مخزن GitHub به صورت ماتژولار طراحی شده است تا جداسازی مناسبی بین بخش‌های مختلف پیاده‌سازی ایجاد شود.

ساختار پوشه‌ها به شرح زیر است:

(heart_disease_uci.csv) : شامل فایل دیتاست اصلی **data/** •

: شامل نمودارهای تولیدشده برای مقایسه عملکرد مدل‌ها **figures/** •

: شامل فایل گزارش نهایی پژوهه **report/** •

: شامل فایل‌های اصلی پیاده‌سازی مدل **src/** •

در پوشه src دو فایل اصلی وجود دارد:

heart_disease_logistic_regression.py .۱

این فایل شامل مراحل اصلی پروژه است:

- بارگذاری دادهها
- پیش‌پردازش (حذف ویژگی‌ها، مدیریت مقادیر گمشده، نرمال‌سازی)
- پیاده‌سازی دو روش Label Encoding و One-Hot Encoding
- ساخت Pipeline
- اجرای ۱۰-Fold Cross Validation
- محاسبه و چاپ معیارهای ارزیابی

plot_results.py .۲

این فایل مسئول رسم نمودارهای مقایسه‌ای بین دو روش Encoding بوده و نتایج مربوط به معیارهای Precision ، Accuracy و F1-score را به صورت گرافیکی نمایش می‌دهد.

این طراحی مازولار باعث جداسازی منطق آموزش مدل از بخش مصورسازی شده و خوانایی، نگهداری و توسعه کد را بهبود می‌بخشد.